

Porównanie modeli klasyfikacyjnych na podstawie zdjęć rentgenowskich klatki piersiowej.

Kaja Wróblewska

25 stycznia 2026

1 Wprowadzenie

W poniższym sprawozdaniu przedstawiono porównanie modeli klasyfikacyjnych przyporządkujących adekwatne choroby do zdjęć rentgenowskich płuc.


2 Dane

Do tworzenia modelu wykorzystano dane treningowe *ChestMNIST* ze zbioru *MedMNIST* - ustandaryzowanych baz danych obrazów biomedycznych do klasyfikacji. Wybrany zbiór składał się z 112 120 frontowych zdjęć klatki piersiowej pochodzących z 30 805 pacjentów. Każde zdjęcie posiada przypisaną etykietę w postaci wektora binarnego 14 możliwych schorzeń: niedodma, kardiomegalia, wysięk, naciek, masa, guzek, zapalenie płuc, odma opłucnowa, zagęszczenia, obrzęk, rozedma, włóknienie, choroba opłucnej, przepuklina. Zdjęcia zostały ustandaryzowane do formatu $1 \times 28 \times 28$ i podzielone na 3 podzbiory: treningowy, walidacyjny i testowy.

3 Przygotowanie danych

W pierwszym kroku dane znormalizowano na podstawie wartości średniej i odchylenia standardowego wyliczonego na zbiorze treningowym. Następnie przeprowadzono analizę dystrybucji klas i zauważono niewystarczającą reprezentację niektórych kategorii. Skutkowało to usunięciem prawie 4 tysięcy przypadków (pozostało ok 111 tys.). Dalsza analiza dotyczy 8 (niedodma, wysięk, naciek, masa, guzek, odma opłucnowa, zagęszczenia, choroba opłucnej) z 14 kategorii, których liczebność przekraczała 2000 próbek.

Co więcej, sprawdzono charakter wieloklasowości danych - ponad 18% przypadków ma przypisanych więcej niż 1 kategorię w oryginalnym zbiorze danych.



Rysunek 1: Histogramy przedstawiające dystrybucje danych

3.1 CNN - Konwolucyjne sieci neuronowe


Pierwszą iteracją modelu była 2-warstwowa konwolucyjna sieć neuronowa, która wykorzystywała warstwy Conv2d, BatchNorm i ReLU do ekstrakcji cech oraz MaxPool2d do redukcji wymiarów obrazu. Biorąc pod uwagę znaczącą nadreprezentację próbek zaklasyfikowanych jako 'zdrowe', jako kryterium optymalizacji przyjęto funkcję kosztu BCEWithLogitsLoss z parametrem *pos_weight* (waga pozytywna), który nadaje większą wagę rzadziej występującym przypadkom patologicznym. BCE zostało użyte ze względu na charakter działania - sprawdza ono każdą klasę niezależnie. Pozwala to modelowi poprawnie zaklasyfikować pacjenta, który ma jednocześnie np. niedodmę i wysięk opłucnowy.

Jako metryki użyto F1 score micro i macro przedstawiające średnią harmoniczną precyzji (*Precision* oraz pełności (*Recall*, w celu lepszej oceny niezbalansowanych klas.

- F1 micro oblicza globalną liczbę trafień (True Positives) i błędów; pokazuje jak model radzi sobie z najpopularniejszymi etykietami.
- F1 Macro oblicza wynik niezależnie dla każdej klasy (choroby), a następnie wyciąga z nich średnią, dzięki czemu rzadkie przypadki patologiczne są traktowane z taką samą wagą jak klasy dominujące.

Dodano też ogólną metrykę dokładności *Accuracy* obliczaną jako średnia z porównań każdego pojedynczego przewidywania z etykietą rzeczywistą. Wszystkie metryki są liczone w sposób *element-wise*.

3.2 CNN1



Rysunek 2: Pierwsza iteracja modelu CNN

Dzięki zastosowaniu mechanizmu *Early stopping* uczenie zatrzymano na 17 epoche. Najlepszy model wystąpił w epoce 12. Mimo wysokiej dokładności ogólnej (72%) w pozostałych metrykach model nie osiągnął satysfakcjonujących wyników: 0.26/0.25 F1 micro/macro. Co więcej zauważono problem z generalizacją modelu. Przed stworzeniem kolejnej iteracji przetestowano różne hiperparametry, jednakże nie dało to znaczącej poprawy.

Model	F1 micro	F1 macro	Test accuracy
CNN1.1	0.2574	0.2453	0.7249
CNN1.2	0.2742	0.2432	0.7169
CNN1.3	0.2645	0.2379	0.7079
CNN1.4	0.2699	0.2403	0.7383

W kolejnych wersjach zaadresowano problem braku generalizacji, dodając kolejno regularyzacje (*weight-decay*) wraz ze zmianą optymalizatora na AdamW [CNN2] oraz dropout'u [CNN3]. Niestety, nie dało to satysfakcjonującej poprawy.

Model	F1 micro	F1 macro	Test accuracy
CNN2.1	0.2616	0.2367	0.7226
CNN2.2	0.2621	0.2332	0.7261
CNN2.3	0.2678	0.2335	0.7197
CNN2.4	0.2615	0.2352	0.7292
CNN2.5	0.2613	0.2366	0.7577
CNN2.6	0.2564	0.2348	0.699
CNN3.1	0.2618	0.2416	0.7322
CNN3.2	0.2794	0.2473	0.7449
CNN3.3	0.2587	0.2402	0.713

W ostatniej iteracji modelu dodano 3 warstwę. Osiągnięty wynik to F1 micro 0.2816, macro: 0.2500, test accuracy: 0.7652.